

Deep Learning of Texture and Structural Features for Multiclass Alzheimer's Disease Classification - 2017

Norfolk University

Problema:

nan

Contribuição:

Os autores propõem uma característica de textura para a classificação de imagens via multiclass, além de definir um modelo deep learning para isso.

Resultado:

O sistema apresentou dois modelos para detecção de Alzheimer via Deep Learning, entretanto, os resultados não ultrapassaram 60% de acurácia

Fluxo:

Dataset - Préprocessamento - Extração de característica - Seleção de característica - LASSO/Elastic Net

Metodologia:

São apresentados dois modelos, um utilizando LASSO e o outro utilizando elastic net, os autores apresentaram também a validação de 10fold e caddementia

Relevancia:

Pois apresenta uma relação em diversos passos para a caracterização do alzheimer em estágios iniciais

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Subcortical/ WM GM Cortical

Metricas:

Accuracy

Resultado Valores:

Model 1: 56.6% Validation ACC - 73.3% CaDDementia ACC --- Testset 62.1%AD, 54.5%MCI, 39.5%NC .

Model 2: LassoTexture SAE 64.1%AD, 51.6%MCI, 55.8%CN

Divisão Avaliação:

10fold cross validation e CADDementia

FuseMe: Classification of sMRI images by fusion Deep CNNs in 2D+ ? projections - 2017

University of Bordeaux

Problema:

A apresentação da necessidade de uso de outras faces do cérebro

Contribuição:

Os autores propõem uma abordagem multiprojeção fusion com CNN para diagnosticar alzheimer, fundindo via voto majoritário diferentes projeções cerebrais

Resultado:

O sistema realiza diferentes comparações permutando os tipos de imagens, além de comparar inicialmente os resultados nas projeções, e por fim a fusão delas. Um ponto interessante é analisar que é possível extrair características importantes de outras projeções cerebrais

Fluxo:

Alinha imagens - préprocessa - AAL para hipocampo - 3d para 2d - funde as imagens de diferentes projeções - usa voto majoritario de diferentes CNN

Metodologia:

Os autores propõem um modelo complexo, que deve ser iniciado gerando uma ROI para o hipocampo. Este passo é realizado através do alinhamento e normalização da intensidade da imagem para entrar em conformidade com atlas AAL. Após estes passos de pré-processamento, os voxels são selecionados para captação do volume, a imagem, atualmente 3D é processada para a retirada de slices 2D. Ao passo final, é aplicado uma CNN de diversas formas utilizando RELU como função de ativação. Por fim, usando todas as CNN, é declarado um

ensemble via voto majoritário, e assim finalizado o algoritmo.

Relevancia:

Pois apresenta que não apenas imagens de projeções axiais devem ser levadas em consideração para a análise do alzheimer

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Hipocampo

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Ac: 71,61% Sp: 70,61, Se: 72,74

Divisão Avaliação:

Train,Test

Automatic Detection and Classification of Alzheimer's Disease From MRI Scans Using
Principal Component Analysis and Artificial Neural Networks - 2013
University of Bridgeport

Problema:

Segundo os autores, existe a dificuldade de encontrar alzheimer e diferencia-los em seus passos intermediários.

Contribuição:

Os autores propõem um método matemático e de processamento de imagens para classificar imagens de alzheimer. Além disso, os autores colocam os outputs em 5

Resultado:

nan

Fluxo:

Pre-processing - PCA - Projection on eigenfaces - neural nets

Metodologia:

Primeiro as imagens são normalizadas de forma que cada imagem se torna uma $n \times 1$. Logo após, o PCA é aplicado e reduz a 150 características, detectando assim as eigenfaces, a imagem é projetada e por fim classificada usando uma MLP

Relevancia:

nan

Imagem:

MRI, Dataset: OASIS

Ranking/Neural:

Neural

ROI:

No ROI

Metricas:

Accuracy

Resultado Valores:

Ac: 89,22%

Divisão Avaliação:

Train,Test

A Feasibility Study of Using the NeuCube Spiking Neural Network Architecture for
Modelling Alzheimer's Disease EEG Data - 2015
Auckland University of Technology

Problema:

Usar um tipo de estrutura diferente para avaliação do alzheimer

Contribuição:

Os autores apresentam uma ideia utilizando NeoCube referente ao mapeamento dos eletrodos no cerebro

Resultado:

Indices extremamente elevados de acurácia, será que EEG é tão bom assim pra Alzheimer ou os autores cometeram erros na avaliação do método?

Fluxo:

Preprocessing - NeoCube 3D - data extraction - spike train transform - unsupervised learning (memory location) - supervised training

Metodologia:

preprocessa a imagem aplicando filtros de banda, aplica o neocube 3d, extrai dados através da extração de conhecimento, modula o sinal em vetor, aplica uma transformada spike, classifica usando spiking NN, aprendizagem não supervisionada para associação com a localização da memória, treinamento supervisionado

Relevancia:

nan

Imagem:

EEG, Dataset: Own

Ranking/Neural:

Neural

ROI:

Eletrodos

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Todos 100%

Divisão Avaliação:

random sub-sampling validation and LOOCV

Deep Learning in the EEG Diagnosis of Alzheimer's Disease - 2015
Tongji University

Problema:

Tipo de estrutura na deep learning para ajudar a identificar o alzheimer

Contribuição:

Alteração na estrutura deep learning para captação de uma EEG exam

Resultado:

além da alteração da estrutura, todos os casos passam de 80% de acurácia

Fluxo:

EEG - High level of features - several high level of features - divide features eighter AD or Non-AD - Classification

Metodologia:

Inicialmente foi escolhido RBM para treinamento,

Relevancia:

nan

Imagem:

EEG, Dataset: Own

Ranking/Neural:

Neural

ROI:

Eletrodos

Metricas:

Accuracy

Resultado Valores:

Ac: 84%

Divisão Avaliação:

Train,Test

Direct estimation of patient attributes from anatomical MRI based on multi-atlas voting - 2016

Johns Hopkins University School of Medicine

Problema:

nan

Contribuição:

Um método multi-atlas associado a demencia ou certas características ela

Resultado:

nan

Fluxo:

Multiatlas segmentation - estratégia de ponderação do atlas - mav attribute estimation

Metodologia:

Inicialmente a imagem é parcelada depois do registro, usando operações affine, logo após, o atlas é associado a pesos para cada estrutura baseada na similaridade label-by-label, ao final, é utilizado o MAC para informação clinica ou demografica

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

No ROI

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

88%

Divisão Avaliação:

Train,Test

Deep Spectral-Based Shape Features for Alzheimer's Disease Classification - 2016

Medical, Polytechnique Montreal, Montreal

Problema:

nan

Contribuição:

Eles propõem um método deep learning baseado nas estruturas da morfologia do hipocampo,

Resultado:

Ganho de acurácia só com a utilização do hipocampo

Fluxo:

Feature extraction - graph modelling - vertex coordinate generation - autoencoder - MLP

Metodologia:

extraí as estruturas da superfície do hipocampo, após essa extração dessa superfície é utilizado uma abordagem que casa estruturas espectrais, logo após é modelado em grafos com características similares, os vértices são usados com descritores de forma, uma variação do autoencoder é utilizado para obter os descritores, e por fim classificar via MLP

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Hipocampo

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Ac: 85%

Divisão Avaliação:

Train,Test

Multimodal Neuroimaging Feature Learning for Multiclass Diagnosis of Alzheimer's Disease - 2015

University of Sydney

Problema:

Não obter o necessário apenas de um exame

Contribuição:

Sistema multimodal via deep learning

Resultado:

nan

Fluxo:

Data acquisition - Preprocessing - Feature Extraction and Selection - Split Test/Train - Deep Learning via SAE - Prediction

Metodologia:

as imagens PET e MRI são adquiridas, para cada 3d é extraído 83 regiões, extrai a matéria cinza, então as características são normalizadas, para a função sigmoid, um SAE é usado para treinar de forma não supervisionada, logo após, os exames são fundidos... ao final, é realizado uma tunagem no código com o softmax e então classificado

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

83 estruturas

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Ac: 82%, Se:60, Sp:92

Divisão Avaliação:

Train,Test

ANN based Dementia Diagnosis using DCT for Brain MR Image compression - 2013

College of Engg. Pandharpur

Problema:

Doença de Huntington muito parecido com o alzheimer em certos estágios

Contribuição:

apresenta um método com aplicações matemáticas simples para identificar fielmente o alzheimer

Resultado:

nan

Fluxo:

Data Acquisition - Histogram - Cosine Transform - Coef to ANN - six absolute largest

Metodologia:

inicialmente, o histograma das intensidades são computados e usados na transformada cosseno, ao final, extrai-se 6 características dele no segundo estágio, é aplicado uma rede neural para classificação

Relevancia:

nan

Imagem:

MRI, Dataset: AANLIB

Ranking/Neural:

Neural

ROI:

No ROI

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

100

Divisão Avaliação:

Train,Test

Diffusion Tensor Imaging retrieval for Alzheimer's disease diagnosis - 2014 University of Bordeaux

Problema:

A MRI já apresenta o potencial quando combinado com outras técnicas, mas perde informações pelo baixo contraste

Contribuição:

inserir um método CBIVR para DTI

Resultado:

nan

Fluxo:

Mean Diffusivity - Preprocessing - Query and Maps - Feature Extraction - features analysis - similarity match - retrieved images

Metodologia:

Mean diffusivity para identificar o hipocampo, com eddy currents, head motion, skull stripping e fitting logo após na extração de características e usado o AALA para extrair essa ROI, usando assim a mascara do hipocampo por fim, utilizando uma função de similaridade é gerado um matching de imagens similares e assim recuperadas as imagens

Relevancia:

nan

Imagem:

DTI, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

hipocampo

Metricas:

Precision

Resultado Valores:

70%

Divisão Avaliação:

Train,Test

Classification of Alzheimer's disease subjects from MRI using hippocampal visual features - 2014 University of Bordeaux

Problema:

A necessidade da geração de similaridade por conteúdo para o reconhecimento do Alzheimer

Contribuição:

Um método automatico para reconhecimento de alzheimer baseado no conteudo da imagem, além de combinar informações de volume e imagem

Resultado:

A combinação entre volume e imagem apresenta resultados promissores, com certeza, principalmente para o alzheimer em estágios mais avançados, ter o uso do volume é algo importante

Fluxo:

Extract content - Normalize - extract hippocampus - signature generation - csf volume - classification

Metodologia:

Primeiro, o conteudo é extraído de informações visuais do hipocampo na imagem, este foi obtido usando AAL, depois a imagem do cerebro é normalizada em tamanho e orientação. A região do hipocampo é tomada como uma ROI, uma geração de assinatura é computada, para conseguir as características da imagem, neste caso usando CHF. O volume CSF é computado com o hipocampo como biomarcador, por fim, a classificação via SVM e Naive Bayes é realizada e o algoritmo é finalizado

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI, Bordeaux

Ranking/Neural:

CBIR

ROI:

Hipocampo

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Ac: 80.61 Sp: 85 Se: 74,30

Divisão Avaliação:

Leave-One-Out Cross-Validation

Discrimination between Alzheimer's Disease, Mild Cognitive Impairment and Normal Aging Using ANN Based MR Brain Image Segmentation - 2014 Noorul Islam University

Problema:

necessidade de utilizar as características de textura em imagens neurologicas

Contribuição:

método que envolve análise de textura, e ann em imagens

Resultado:

nan

Fluxo:

Preprocessing-Feature extraction - ANN - Classification

Metodologia:

Inicialmente, as imagens são preprocessadas usando skull stripping, depois a imagem é segmentada usando características de textura, neste caso usando filtros de Gabor, logo após é aplicado uma rede neural com as características obtidas no filtro de gabor, por fim, as imagens são classificadas utilizando características de gm, wm, csf

Relevancia:

nan

Imagem:

MRI, Dataset: x

Ranking/Neural:

Neural

ROI:

GM, WM, CSF

Metricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Ac:96,32 Sp: 97,97 Se:93,92

Divisão Avaliação:

Train,Test

Deep Ensemble Sparse Regression Network for Alzheimer's Disease Diagnosis - 2016 Korea University

Problema:

analisar um conjunto grande de dados quando só alguns estão disponíveis

Contribuição:

propor um modelo que relacione regressão logística e CNN

Resultado:

nan

Fluxo:

Preprocessing-segmentation-parcellation-logistic regression - CNN

Metodologia:

Os autores preprocessam a imagem usando resampling 256^3 , com inhomogeneity, skull stripping e cerebelum removal, logo após é usada a segmentação das matérias branca e cinza, bem como o CSF. O parcelamento é realizado para a obtenção das ROIs, uma regressão logística é aplicada para alimentar a rede neural, e por fim, um CNN para realizar a classificação

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

GM,WM,CSF

Métricas:

Accuracy, Specificity, Sensitivity

Resultado Valores:

Ac: 79.25 Sp: 80,66 Se: 76,88

Divisão Avaliação:

10-fold cross-validation

Automatic Recognition of Mild Cognitive Impairment from MRI Images Using Expedited Convolutional Neural Networks - 2017 Chinese Academy of Sciences

Problema:

a dificuldade em encontrar MCI, visto que diversos métodos apresentam alta acurácia em AD x NCI

Contribuição:

Apresentar uma variação da CNN com decomposição Turker para identificar MCI

Resultado:

nan

Fluxo:

Feature Map - CNN

Metodologia:

o kernel de convolução, bem como a amostra de treinamento são decompostos via turker, , depois, nove layers são utilizadas, desde a entrada até a saída, os autores escolheram RELU para a função de ativação

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI, LIDC, OASIS

Ranking/Neural:

Neural

ROI:

No ROI

Metricas:

F-measure, Precision, Recall, Accuracy

Resultado Valores:

F: 89.4 Ac: 90.6 Rec:92.8 Prec: 87.2

Divisão Avaliação:

train-validation-test

Robust Deep Learning for Improved Classification of AD/MCI Patients - 2014

Old Dominion University

Problema:

nan

Contribuição:

nan

Resultado:

nan

Fluxo:

nan

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

CSF

Metricas:

Accuracy

Resultado Valores:

75.4

Divisão Avaliação:

ten-fold cross validation

Content-Based Retrieval of Brain Diffusion Magnetic Resonance Image - 2015

University of Sydney

Problema:

Usar CBIR em imagens de difusão magnética

Contribuição:

Os autores propõem um framework que recupera imagens similares de alzheimer (DTI)

Resultado:

Utilização do MAP mostrou que o algoritmo, apesar de inicial, pode vir a apresentar bons resultados no futuro

Fluxo:

Masking via AAL - Estimation - Hyperparameter - Feature selection - Similarity Matrix - Fusion - Reranking

Metodologia:

A máscara é obtida inicialmente via AAL, depois, um algoritmo determinístico é utilizado para relaizar a estimação. A matrix é reconstruida através dos hiperparametros calculados desta forma. Uma Elastic Net é usada para selecionar as características. Os cálculos dos dados utilizando função Jaccart é usada para gerar a matrix de

similaridade. As queries de diferentes imagens são fundidas para assim, através do reranking, gerar uma representação fiel do relacionamento dos dados.

Relevancia:

nan

Imagem:

DTI, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

nan

Metrics:

MAP

Resultado Valores:

66.46

Divisão Avaliação:

leave-one-out

A novel Convolutional Neural Network Model Based on Voxel-based Morphometry of Imaging Data in Predicting the Prognosis of Patients with Mild Cognitive Impairment - 2017 Yeditepe University,

Problema:

A necessidade de um algoritmo eficiente que consiga realizar o prognóstico em estágios prodômicos do alzheimer

Contribuição:

um algoritmo que utiliza imagens prodômicas do alzheimer, e assim efetua uma inferencia com eles. Os dados na literatura utilizam a maioria a comparação de NC vs AD, pois é mais fácil discriminar

Resultado:

o algoritmo foi testado com o alcance de 78% de acurácia

Fluxo:

Feature Extraction - Filter generation - Classification

Metodologia:

É aplicado um processamento morfométrico por voxel na matéria cinza danificada para encontrar as VOI, essas VOI serão utilizadas para treinar um autoencoder e assim gerar os filtros, por fim, é aplicado a CNN para efetuar o prognóstico do paciente.

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

GM

Metrics:

Accuracy, Specificity, Sensitivity

Resultado Valores:

78.7%acurácia

Divisão Avaliação:

ten-fold cross-validation

EEG discrimination with artificial neural networks - 2013 Instituto Politécnico de Bragança

Problema:

A ineficácia de algoritmos atuais para detectar alzheimer

Contribuição:

Um algoritmo que utiliza sinais EEG e potencializa a detecção do Alzheimer

Resultado:

nan

Fluxo:

Signal Processing - Feature Extraction - Classification

Metodologia:

Primeiro, é aplicado a Transformada de Fourier pra obter o sinal no domínio da frequência. Com os dados em domínio da frequência, é possível aplicar o poder relativo na bandas EEG. Por fim, uma ANN é utilizada para discriminar os sinais

Relevancia:

nan

Imagem:

EEG, Dataset: Own

Ranking/Neural:

Neural

ROI:

NO ROI

Metricas:

Accuracy

Resultado Valores:

96.13%

Divisão Avaliação:

TrainRP

Elman neural network for the early identification of cognitive impairment in Alzheimer's disease - 2014 IRCCS Centro Neurolesi

Problema:

A necessidade a algoritmos que identifique o alzheimer através de EEG

Contribuição:

um algoritmo que engloba o uso de wavelet, ann e algoritmo genético

Resultado:

um método que supera 84%

Fluxo:

Filtering - Feature extraction - calculate MF and PP

Metodologia:

nan

Relevancia:

nan

Imagem:

EEG, Dataset: Own

Ranking/Neural:

Neural

ROI:

NO ROI

Metricas:

Accuracy

Resultado Valores:

84%

Divisão Avaliação:

Train,Test

Propagation Graph Fusion for Multi-Modal Medical Content-Based Retrieval - 2014

Problema:

A necessidade de unir a multimodalidade para geração de um prognóstico prévio

Contribuição:

Apresenta funções utilizadas e framework utilizados. Ilustra os conceitos através de imagens e os resultados são satisfatórios

Resultado:

nan

Fluxo:

Preprocessing - Feature Extraction - Graph Construction - Graph Fusion

Metodologia:

Inicialmente, as imagens são obtidas da base de dados ADNI, depois é realizada uma correlação entre as imagens PET+MRI, com o PET sendo alinhado ao MRI através do FSL FLIRT, uma Elastic Registration é aplicada e os coeficientes de volume PET são obtidos. O próximo passo é a extração de características, para cada imagem é utilizada uma extração diferente. Para PET, os dados de voxel cerebral metabólico e lesão centrada são obtidos. Para MRI, o volume da matéria cinza e o atrofamento cortical são obtidos. Na construção do grafo de similaridade, são gerados vários grafos para corresponder a todo o conjunto amostral e também as 4 características extraídas. Por fim, estes grafos, que são agrupados por queries, são fundidos através de uma função de similaridade.

Relevância:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

Voxel cerebral metabólico, lesão centrada, matéria cinza, atrofamento cortical

Métricas:

MAP

Resultado Valores:

78.1

Divisão Avaliação:

leave-one-out crossvalidation

Deep Residual Nets for Improved Alzheimer's Diagnosis - 2017

Swarthmore College

Problema:

Dificuldade em se obter apoio automatizado para diagnóstico da doença por limitação do tamanho dos conjuntos de imagens

Contribuição:

Modelos de rede residual pré-treinada (ResNet) com imagens não médicas para prever Alzheimer's

Resultado:

Aumento de acurácia ao utilizar redes pré-treinadas

Fluxo:

Seleção data set (MRI) - Treino/teste

Metodologia:

Foram escolhidas as imagens do banco ADNI (660 no total), dividido-as na proporção 80/20 treino/teste. Duas redes foram treinadas, pretrained ResNet e CNN (para servir de base). Comparou-se os resultados entre Baseline CNN, ResNet, Pretrained ResNet e uma variação (augmentation).

Relevância:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Undefined

Metricas:

Accuracy

Resultado Valores:

AD vs. CN: 81,3%; AD vs. MCI vs. CN: 56,8%)

Divisão Avaliação:

Train, Test

Content Based Retrieval of MRI on Brain Structure Changes in Alzheimer's Disease - 2015

Rugjer Boshkovikj University

Problema:

CBIR de MRI baseado em mudanças de estruturas cerebrais características da AD. Conseguir melhorar performance utilizando número menor de características em comparação com técnicas de extração de características tradicionais.

Contribuição:

nan

Resultado:

Aumento na precisão com menor número de característica sendo analisadas

Fluxo:

Seleção data set (MRI) - Segmentação de imagens e medidas quantitativas de volume cortical - Representação de características - Cálculo de similaridade - MAP

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

15 - 17 features

Metricas:

Precision

Resultado Valores:

1,5T MAP: 0,75/ 3T MAP: 0,46

Divisão Avaliação:

MAP

AUTOMATED FEEDBACK EXTRACTION FOR MEDICAL IMAGING RETRIEVAL - 2014

University of Sydney

Problema:

Necessidade de obter feedback do radiologista para relevancia/irrelevância de imagens recuperadas

Contribuição:

Metodo de CBIR com feedback de relevância automatizado Aao invés de feedbak do usuário

Resultado:

Aumento na preciação média AP,

Fluxo:

Query Image - Lista de resultados inicial - Procedimento de extração de Feedback Iterativo

Metodologia:

Usando uma imagem de consulta, um processo de recuperação é conduzido, produzindo uma lista ranqueada inicial de imagens recuperadas com base na extração de características e cálculo de similaridade. Para a etapa de feedback de relevância, as relações de similaridade entre as imagens recuperadas e todos os candidatos são estabelecidas e utilizadas para re-ranquear os candidatos de forma iterativa.

Relevancia:

Utiliza técnicas de re-ranking de imagens

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

7 features

Metricas:

Precision

Resultado Valores:

Proposed method: 15% higher in the best scenario

Divisão Avaliação:

Average Precision/Leave-one-out

Alzheimer's Disease Classification Based on Combination of Multi-model Convolutional Networks - 2017

Shanghai Jiao Tong University

Problema:

Necessidade de haver ROIs para que os estudos possam ser feitos

Contribuição:

O método propõe-se a aprender características genéricas das imagens para classificação sem segmentações de tecido ou regiões.

Resultado:

Aumento na acurácia na classificação utilizando o método proposto

Fluxo:

nan

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

-

Metricas:

Accuracy

Resultado Valores:

Ac: 88,31%

Divisão Avaliação:

nan

Combining Convolutional and Recurrent Neural Networks for Alzheimer's Disease Diagnosis Using PET Images - 2017

Shanghai Jiao Tong University

Problema:

Necessidade de haver ROIs / segmentação para que os estudos possam ser feitos

Contribuição:

Novo framework de classificação baseado na combinação de CNN e BGRU. Não necessita segmentação das imagens

Resultado:

Acurácia, especificidade e sensibilidade maiores quando comparados com outras metodologias

Fluxo:

nan

Metodologia:

nan

Relevancia:

nan

Imagem:

PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

-

Metricas:

Accuracy

Resultado Valores:

AD: ACC 91.19, SEN 91.40, SPE 91.00, AUC 95.28 / MCI: ACC 78.86 SEN 78.08 SPE 80.00 AUC 83.90

Divisão Avaliação:

10-fold cross validation

Applying Convolutional Neural Networks for Pre-detection of Alzheimer's Disease from
Structural MRI data - 2017
University of Colombo (Sri Lanka)

Problema:

Pre-deteccção doença de Alzheimer's

Contribuição:

Foram utilizados dois modelos. SVM e CNN, sendo o último com melhor desempenho

Resultado:

nan

Fluxo:

Seleção dataset - manipulação imagens (redução de ruído, etc.) - detecção de bordas - segmentação - extração de características e classificação

Metodologia:

Verificar métodos existentes de identificação automatizada. Se fosse bom, utilizar esse método, caso contrário, propor um novo método. SVM utilizado primeiro. Em seguida CNN.

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Cortex, hipocampo, ventriculo

Metricas:

Accuracy

Resultado Valores:

SVM: Ac: 84,4%, Se: 95,3%, Sp: 71,4% / CNN: Ac: 96% , Se: 96%, Sp: 98%

Divisão Avaliação:

Train, Test

A Deep CNN based Multi-Class Classification of Alzheimer's Disease using MRI - 2017

National University of Science and Technology (NUST) / Surrey University

Problema:

Deteção de Alzheimer's em estágios iniciais

Contribuição:

A classificação é feita em 4 categorias CN - MCI - LMCI - AD e consegue acurácia de 98%

Resultado:

Altíssima acurácia quando comparado com outras metodologias que classificam 3 ou 4 categorias

Fluxo:

MRI Scan - Processamento da imagem - Fatia matéria cinzenta - CNN - Grupo diagnóstico (AD-LMCI-MCI-CN)

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Ac: 98,8%

Divisão Avaliação:

nan

CNN's based Multi-Modality Classification for AD Diagnosis - 2017

Shangai Jiao Tong University

Problema:

Pre-deteção doença de Alzheimer's

Contribuição:

Utiliza multimodalidade e redes 2D e 3D

Resultado:

nan

Fluxo:

Imagens MRI e PET - 3D CNN - 2D CNN - classificação (AD ou CN)

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

ACC(%) 89.64 SEN(%) 87.10 SPE(%) 92.00

Divisão Avaliação:

10-fold cross validation

Ensembles of Deep Learning Architectures for the Early Diagnosis of Alzheimer's Disease - 2016

University of Malaga

Problema:

Pre-deteção doença de Alzheimer's

Contribuição:

Construção de método de classificação baseado em Deep Learning aplicados a regiões definidas por Automatic Anatomical Labelling (AAL)

Resultado:

Acurácia na classificação em si e método para determinar as ROIs mais "discriminativas"

Fluxo:

Dataset selection - Voxel selection - brain parcellation - Deep belief networks - Voting scheme - Conjunto decisão

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Ac: 90% Se: 86%, Sp: 94%

Divisão Avaliação:

10-fold cross validation

Hierarchical Feature Representation and Multimodal Fusion with Deep Learning for AD/MCI Diagnosis - 2014

University of North Carolina - Chapel Hill

Problema:

Ao tentar utilizar informações multimodais simplesmente concatenavam as informações de cada modalidade

Contribuição:

Representação e fusão das informações de MRI e PET por meio de representação de features compartilhadas entre as multimodalidades via deep learning.

Resultado:

Deep Boltzmann Machine para encontrar representações de características hierarquicas compartilhadas. Alta acurácia

Fluxo:

Input de imagens multimodalidade - Extração de recortes da imagem (patches) - Aprendizado de features a nível dos recortes - Aprendizado classificador a nível da imagem

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Ac: 95,35% (AD vs. CN) / 85,67% (MCI vs. CN) / 74,58% (MCI-C vs. MCI-NC)

Divisão Avaliação:

10-fold cross validation

Latent feature representation with stacked auto-encoder for AD/MCI diagnosis - 2015

University of North Carolina, Chapel Hill, Korea University

Problema:

Classificação diferentes estágios

Contribuição:

Representação de features latentes baseadas em deep learning com stacked auto encoders (SAE)

Resultado:

Boa acurácia na classificação de diversas categorias

Fluxo:

nan

Metodologia:

Pre-treino SAE "greedy layer-wise (?)" para obtenção de parâmetros iniciais. Afinou deep-network para encontrar parâmetros ótimos. Concatenação das características low-level e as características aprendidas por SAE. Fundição das info características multooodais via SVM

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

98.8, 90.7, 83.7, and 83.3 % for AD/HC, MCI/HC, AD/MCI, and MCI-C/MCI-NC classification, respectively.

Divisão Avaliação:

10-fold cross validation

A Robust Deep Model for Improved Classification of AD/MCI Patients - 2015

University of North Carolina - Chapel Hill

Problema:

nan

Contribuição:

Prevenir co-adaptação de pesos que acabam causando over-fitting

Resultado:

Aumento de acurácia

Fluxo:

Dataset selection - extração de características - análise dos principais componentes de cada modalidade - seleção de estabilidade - multi-task deep learning com dropout - diagnóstico de AD/MCI com SVM

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

91.4%, 77.4%, 70.1% and 57.4% accuracies for AD vs HC, MCI vs HC, AD vs MCI, and MCI.c vs MCI.NC classifications, respectively.

Divisão Avaliação:

10-fold cross validation

Convolutional Neural Networks for the Identification of Regions of Interest in PET Scans: A Study of Representation Learning for Diagnosing Alzheimer's Disease - 2017
Johannes Gutenberg-Universität

Problema:

Necessidade de escolher ROIs para detecção de Alzheimer

Contribuição:

Identificação de ROIs

Resultado:

Acurácia parecida de outros métodos mas com seleção de ROI a partir de classificador binário CNN

Fluxo:

Data set selection - Normalização - Geração de classificadores binários - Descoberta de ROI e Ranking

Metodologia:

nan

Relevancia:

nan

Imagem:

PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Ac: 89%

Divisão Avaliação:

10-fold cross validation

Deep Learning based Classification of FDG-PET Data for Alzheimer's Disease Categories - 2017
Arizona State University

Problema:

Eficácia do PET sozinho

Contribuição:

Novos métodos de análise probabilística de componente principal em max-pooled e mean-pooled data

Resultado:

Aumento de acurácia quando comparado com outros estudos que utilizam apenas PET

Fluxo:

Raw PET image - normalized PET image - Pooling - PCA probabilístico - Perceptron Multicamadas

Metodologia:

nan

Relevancia:

nan

Imagem:

PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

F1-Score, Precision, Recall

Resultado Valores:

nan

Divisão Avaliação:

10-fold cross validation

Classification of Alzheimer's Disease by Cascaded Convolutional Neural Networks Using
PET Images - 2017
Shanghai Jiao Tong University

Problema:

Necessidade de alguém escolher as características a partir da imagem

Contribuição:

Rede 3D-CNN em cascata para escolher as características relevantes

Resultado:

nan

Fluxo:

nan

Metodologia:

nan

Relevancia:

nan

Imagem:

PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Ac: 92%

Divisão Avaliação:

10-fold cross validation

Diagnostic Support for Alzheimers Disease through Feature-Based Brain MRI Retrieval and
Unsupervised Distance Learning - 2016
Unesp

Problema:

Suporte a diagnostico precoce

Contribuição:

Recuperação de imagens sem necessidade de pré-processamento de imagens

Resultado:

Boa precisão e utilização de re-ranking de imagens

Fluxo:

Seleção dataset - extração de características - cálculo de distâncias e listas ranqueadas - aprendizado não-supervisionado - resultado recuperado

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI, OASIS

Ranking/Neural:

CBIR

ROI:

nan

Metricas:

nan

Resultado Valores:

nan

Divisão Avaliação:

nan

Feature Learning and Fusion of Multimodality Neuroimaging and Genetic Data for Multi-status Dementia Diagnosis - 2017 University of North Carolina - Chapel Hill

Problema:

nan

Contribuição:

Aumento da multimodalidade utilizando além de MRI e PET, informações genéticas

Resultado:

nan

Fluxo:

Soft-max classifier para cada modalidade - soft-max classifier para cada combinação de duas modalidades - um último soft-max classifier derivado dos anteriores

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, SNP, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

93 ROIs

Metricas:

Accuracy

Resultado Valores:

nan

Divisão Avaliação:

Train, Test

Classification of MR brain images by combination of multi-CNNs for AD diagnosis - 2017 Shanghai Jiao Tong University

Problema:

Necessidade de alguém escolher as características a partir da imagem

Contribuição:

aprender várias features locais de imagens que combinadas fazem a classificação final

Resultado:

nan

Fluxo:

extração de partes locais de imagens- construção de multiplas redes 3d-CNN - classificação

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

93 ROIs

Metricas:

Accuracy

Resultado Valores:

Acc: 87,15% Sen: 86,36% Spe: 85,93%

Divisão Avaliação:

10-fold cross validation

Classification of sMRI for AD Diagnosis with Convolutional Neuronal Networks: A Pilot 2-D
+ (epsilon) Study on ADNI - 2017
Université de Bordeaux

Problema:

nan

Contribuição:

Foco na morfologia hipocampal, além de estratégia de aumento de dados

Resultado:

Boa acurácia utilizando número limitado de cortes consecutivos e apenas um eixo de projeção

Fluxo:

Seleção das imagens - Alinhamento e normalização - Extração Roi (hipocampo) - Extração de partes - CNN -
classificação

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Hipocampo

Metricas:

Accuracy

Resultado Valores:

AD/NC 82.8% MCI/NC 66% AD/MCI 62.5%

Divisão Avaliação:

Train, Test

Image Retrieval for Alzheimer's Disease Based on Brain Atrophy Pattern - 2017

Cybil and Methodius University

Problema:

Recuperação de imagem baseada em padrão de atrofia do cérebro

Contribuição:

nan

Resultado:

nan

Fluxo:

nan

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

nan

Metricas:

Precision, MAP

Resultado Valores:

nan

Divisão Avaliação:

MAP

Deep Learning-based Pipeline to Recognize Alzheimer's Disease using fMRI Data - 2016

University of Toronto

Problema:

nan

Contribuição:

CNN LeNet-5

Resultado:

Alta acurácia

Fluxo:

Aquisição de imagens - Rede LeNet-5 - classificação

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Ac: 96,85%

Divisão Avaliação:

Train, Test

Exploring Alzheimer's anatomical patterns through convolutional networks - 2016

Universidad Industrial de Santander

Problema:

Encontrar quais regiões contribuem mais para a detecção da doença

Contribuição:

Determinar regiões de interesse diversas as estudadas com maior frequência

Resultado:

Região polo frontal obteve melhor discriminação nas redes CNN

Fluxo:

CNN train - criação de um modelo cerebral - discriminação de estruturas cerebrais

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: OASIS

Ranking/Neural:

Neural

ROI:

Left subcallosal cortex (LSC), the left Amygdala (LA) and the left Thalamus (LT).

Metricas:

Area Under Curve, Accuracy, True Positive Rate, False Positive Rate

Resultado Valores:

-

Divisão Avaliação:

Leave-one-out

Dictionary pruning with visual word significance for medical image retrieval - 2016

University of Sydney

Problema:

nan

Contribuição:

nan

Resultado:

nan

Fluxo:

nan

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

CBIR

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

-

Divisão Avaliação:

Retrieval Accuracy

Multi-modality stacked deep polynomial network based feature learning for Alzheimer's disease diagnosis - 2016
Shanghai University

Problema:

nan

Contribuição:

Fusão de multimodalidade

Resultado:

nan

Fluxo:

Dataset - Stacked DPN multi camada - classificador

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

93 ROIs

Metricas:

Accuracy

Resultado Valores:

MM-S-DPN accuracy 97.27±4.39%,

Divisão Avaliação:

10-fold cross validation

Multi-view ensemble learning for dementia diagnosis from neuroimaging: An artificial neural network approach - 2016
Renmin University of China

Problema:

nan

Contribuição:

Framework de aprendizado para criação de modelos para tarefa de classificação AD/MCI

Resultado:

nan

Fluxo:

Dataset - Multiview fusion - ensemble learning - softmax - classificação

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Undefined

Metricas:

Sensitivity, Specificity, Area Under Curve

Resultado Valores:

nan

Divisão Avaliação:

10-fold cross validation

DemNet: A Convolutional Neural Network for the Detection of Alzheimer's Disease and
Mild Cognitive Impairment - 2016
University of Philippines Diliman

Problema:

nan

Contribuição:

Rede VGG_Net de 16 camadas para classificação Ad/MCI/CN

Resultado:

nan

Fluxo:

Seleção de dados - pré processamento - treino - classificador

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Acc: 91,85%

Divisão Avaliação:

Train, Test

Multimodal Neuroimaging Feature Learning With Multimodal Stacked Deep Polynomial
Networks for Diagnosis of Alzheimer's Disease - 2018
Shangai University

Problema:

nan

Contribuição:

Fusão de multimodalidade

Resultado:

nan

Fluxo:

Dataset - Stacked DPN multi camada - classificador

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

93 ROIs

Metricas:

Accuracy

Resultado Valores:

nan

Divisão Avaliação:

10-fold cross validation

Anatomical Landmark based Deep Feature Representation for MR Images in Brain Disease
Diagnosis - 2017

University of North Carolina - Chapel Hill

Problema:

Necessidade de alguém escolher as características a partir da imagem

Contribuição:

aprender várias features locais de imagens que combinadas fazem a classificação final

Resultado:

nan

Fluxo:

Imagens pre-processadas- descoberta de pontos de referencia - extração de partes baseadas nos pontos de referencia - CNN - Classificação e recuperação de imagem

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI, MIRIAD

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

nan

Divisão Avaliação:

Train, Test

Multi-task neural networks for joint hippocampus segmentation and clinical score regression -
2017

Taian Institute of Science and Technology Information

Problema:

Necessidade de segmentação acurada do hipocampo

Contribuição:

Segmentação sem que alguém precise delinear a estrutura

Resultado:

Alto dice similarity coefficient, Sensitivity e Positive predicted value (formulas discriminadas no paper)

Fluxo:

Processamento da imagem via regressão linear - extração de parte da imagem - Multi-task learning - Multi-task CNN - Mapa de probabilidade - Segmentação hipocampal

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

Hipocampo

Métricas:

Dice Similarity Coef, Sensitivity, Positive Predicted Value

Resultado Valores:

nan

Divisão Avaliação:

Train, Test

Alzheimer disease detection from structural MR images using FCM based weighted probabilistic neural network - 2018 Hindusthan College of Engineering and Technology,

Problema:

Pre-deteção doença de Alzheimer's

Contribuição:

To detect and to remove the suspicious samples at the time of training employing the FCM (unsupervised learning) algorithm to the supervised learning technique (WPNN)

Resultado:

Acurácia em torno de 98.63%, 95.4%, 96.4% (in terms of classification with AD vs NC, MCI vs NC and AD vs MCI)

Fluxo:

Data set - Normalização - Extração de ROI - Feature selection textura e forma - Treino/teste - classificador

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Métricas:

Accuracy

Resultado Valores:

accuracy 98.63%, 95.4%, 96.4% in terms of classification with AD vs NC, MCI vs NC and AD vs MCI

Divisão Avaliação:

Train, Test

Deep 3D Convolutional Neural Network Architectures for Alzheimer's Disease Diagnosis - 2018 National Chiao Tung University

Problema:

Pre-deteção doença de Alzheimer's

Contribuição:

architecture used residual connection to prevent feature loss and make deeper architecture applicable to the MRI image

Resultado:

Maior acurácia quando comparado com outros classificadores utilizando menos camadas (39 layers vs. 52 layers ResNet -51)

Fluxo:

Data Set - CNN - Classificador

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Acc: 94% (NC/AD)

Divisão Avaliação:

Train, Test

Multimodal learning using Convolution Neural Network and Sparse Autoencoder - 2017 Chonnam National University

Problema:

Pre-deteção doença de Alzheimer's

Contribuição:

Designed a pattern classification system based on convolution neural networks and sparse autoencoders in a multimodality fusion of MRI and FDG-PET

Resultado:

Method improve highly the classification accuracy in both two directions: fusion modalities versus single modality, as well as CNN classifier with useful pretraining SAE

Fluxo:

Input(MRI/PET) - CNN layer - Pooling layer - Fully-connected layer - softmax (MRI/PET)

Metodologia:

nan

Relevancia:

nan

Imagem:

MRI, PET, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Metricas:

Accuracy

Resultado Valores:

Acc: 90% (NC/AD)

Divisão Avaliação:

Train(80), Test(10), Validation(10)

Classification of sMRI for Alzheimer's disease Diagnosis with CNN: Single Siamese Networks with 2D+? Approach and Fusion on ADNI - 2017 University of Bordeaux

Problema:

Diagnóstico não invasivo de Alzheimer

Contribuição:

Construção de nova metodologia de diagnóstico de AD

Resultado:

Redução do número de brain scan para formação de base de análise com a mesma precisão nos resultados de classificação AD/NC em comparação com métodos mais complexos

Fluxo:

Data set - pré-processamento - ROI - CNN de cada eixo de projeção - fusão - classificador

Metodologia:

nan

Relevância:

nan

Imagem:

MRI, Dataset: ADNI

Ranking/Neural:

Neural

ROI:

nan

Métricas:

Accuracy

Resultado Valores:

Acc: 91%

Divisão Avaliação:

Train(60), Test(20), Validation(20)